

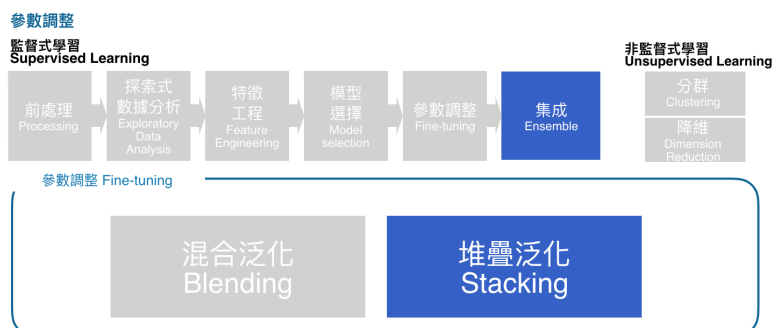
# D50：集成方法：堆疊泛化(Stacking)

[簡報閱讀](#)[範例與作業](#)[問題討論](#)[堆疊泛化\(Stacking\)](#)[知識地圖](#)[本日知識點目標](#)[堆疊泛化 \(Stacking\) 的橫空出世](#)[Stacking 的設計挑戰：訓練測試的不可重複性](#)[Blending 與 Stacking 的原理差異](#)[Stacking 最終設計：巧妙的 K-Fold 拆分](#)[自我遞迴的 Stacking？](#)

## 堆疊泛化(Stacking)



## 知識地圖



## 本日知識點目標

## 今日知識點目標

- 為什麼堆疊泛化看起來這麼複雜？
- 堆疊泛化有堆疊層數上的限制嗎？
- 混合泛化相對堆疊泛化來說，有什麼優缺點？

## 堆疊泛化 (Stacking) 的橫空出世

### Stacking 小歷史

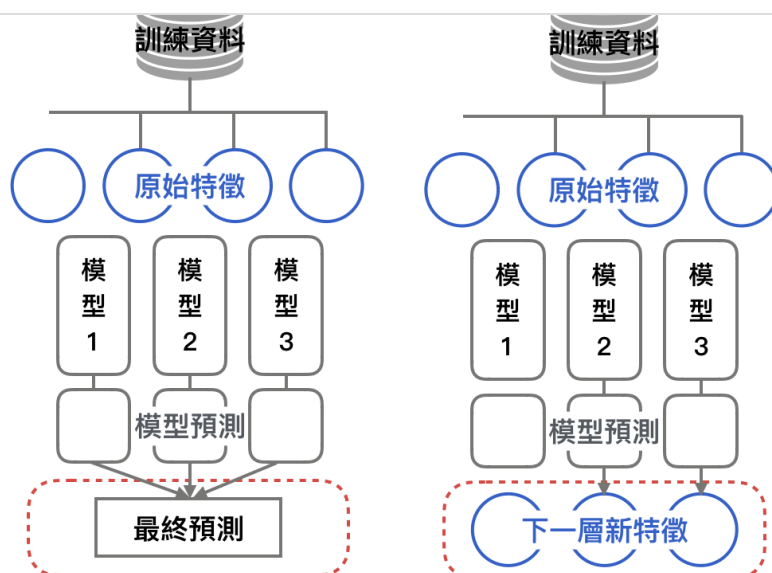
- 雖然堆疊泛化 (Stacking) 的論文早在 2012 年，就由 David H. Wolpert 發布 ([原始論文連結](#))
- 但真正被廣泛應用於競賽上，是2014年底的 Kaggle 競賽開始
- 由於 Kaggle 一直有前幾名於賽後發布做法的風氣，所以當有越來越多的前幾名使用 Stacking
- 後，這個技術就漸漸變得普及起來，甚至後來出現了加速混合與計算速度的 StackNet

### 相對於 Blending 的改良

- 不只將預測結果混合，而是使用[預測結果當新特徵](#)
- 更進一步的運用了[資料輔助集成](#)，但也使得 Stacking 複雜許多


## Stacking 的設計挑戰：訓練測試的不可重複性

Blending 與 Stacking 都是模型集成，但是模型預測結果怎麼使用，是關鍵差異




## Blending 與 Stacking 的原理差異

- Stacking 主要是把模型當作下一階的**特徵編碼器**來使用，但是待編碼資料與用來訓練編碼器的資料不可重複 (訓練測試的不可重複性)
- 若將訓練資料切成兩組：待編碼資料太少，下一層的資料筆數就會太少，訓練編碼器的資料太少，則編碼器的強度就會不夠，這樣的困境該如何解決呢？



- Stacking 最終採取了下圖設計：將資料拆成 K 份 (圖中 K=5)，每  $1/K$  的資料要編碼時，使用其他的 K-1 組資料訓練模型/編碼器
- 這樣資料就沒有變少，K 夠大時編碼器的強韌性也夠，唯一的問題就是計算時間隨著 K 變大而變長，但 K 可以調整，且相對深度學習所需的時間來說，這樣的時間長度也還算可接受




## 自我遞迴的 Stacking ?

- 大家在看到 Stacking 時可能已經注意到了：既然 Stacking 是在原本特徵上，用模型造出新特徵，那麼我們自然會想到兩個問題：  
Q1 能不能新舊特徵一起用，再用模型去預測呢?  
Q2 新的特徵，能不能再搭配模型創特徵，第三層第四層...一直下去呢?

第二層

第三層



Q1：能不能**新舊特徵一起用**，再用模型預測呢？

A1：可以，這裡其實有個有趣的思考，也就是：這樣不就可以一直一直無限增加特徵下去？這樣後面的特徵還有意義嗎？不會 Overfitting 嗎?...其實加太多次是會 Overfitting 的，必需謹慎切分 Fold 以及新增次數

Q2：新的特徵，能不能**再搭配模型創特徵**，第三層第四層...一直下去呢？

A2：可以，但是每多一層，模型會越複雜：因此泛化(又稱為魯棒性)會做得更好，精準度也會下降，所以除非第一層的單模調得很好，否則兩三層就不需要繼續往下了

\*\* 更有趣的其實是下面的問題 (純個人分享，如果感到太抽象的同學可以跳過)

Q3：既然同層新特徵會 Overfitting，層數加深會增加泛化，兩者同時用是不是就能把缺點互相抵銷呢？

個量級，之前曾有大神寫過 StackNet 實現這個想法，用JVM 加速運算，但實際上使用時調參困難，後繼使用的人就少了

## 真實世界的 Stacking 使用心得

### 實際上寫 Stacking 有這麼困難嗎？

其實不難，就像 sklearn 幫我們寫好了許多機器學習模型，mlxtend 也已經幫我們寫好了 Stacking 的模型，所以用就可以了 (參考今日範例或 mlxtrend官網)

### Stacking 結果分數真的比較高嗎？

不一定，有時候單模更高，有時候 Blending 效果就不錯，視資料狀況而定

### Stacking 可以做參數調整嗎？

可以，請參考 mlxtrend 的 [調參範例](#)，主要差異是參數名稱寫法稍有不同

### 還有其他做 Stacking 時需要注意的事項嗎？

「分類問題」的 Stacking 要注意兩件事：記得加上 use\_prob=True(輸出特徵才會是機率值)，以及輸出的總特徵數會是：模型數量\*分類數量(回歸問題特徵數=模型數量)

## 重要知識點複習

- 堆疊泛化因為將模型預測當作特徵時，要避免要編碼的資料與訓練編碼器的資料重疊，因此設計上看起來相當複雜
- 堆疊泛化理論上在堆疊層數上沒有限制，但如果第一層的單模不夠複雜，堆疊二三層後，改善幅度就有限了

## 一步混合模型

## 延伸閱讀



- 除了每日知識點的基礎之外，推薦的延伸閱讀能補足學員們對該知識點的了解程度
- 建議您解完每日題目後，若有多餘時間，可再補充延伸閱讀文章內容

## 推薦延伸閱讀

mlxtend 官方網站 [StackingCVClassifier](#)

**StackingCVClassifier -**

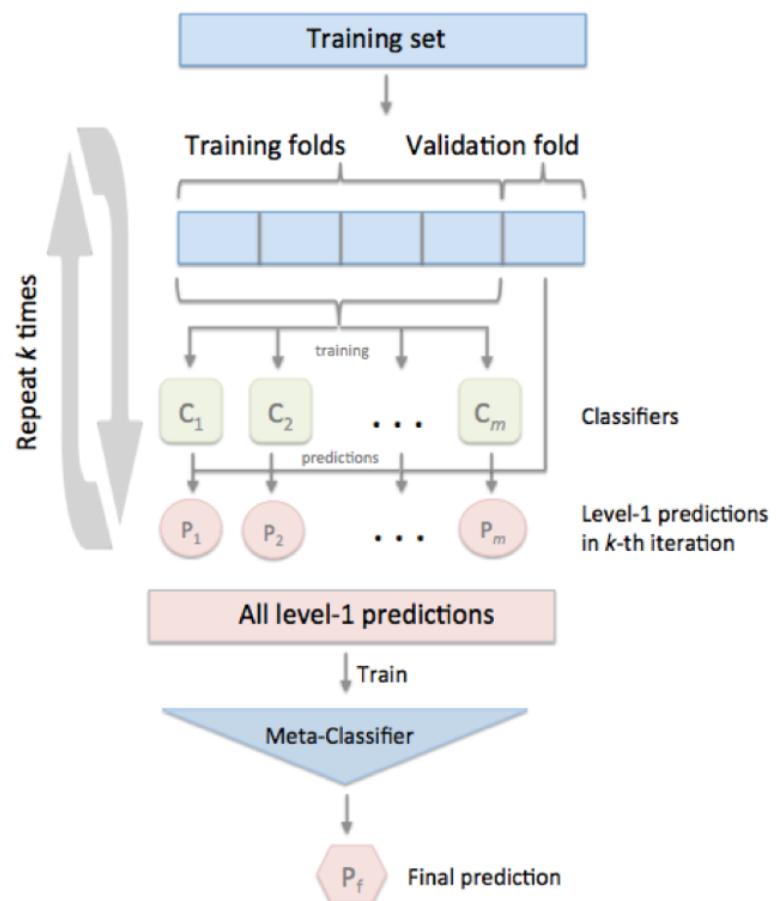
A library consisting of useful tools  
and extensions for the day-to-day

[rasbt.github.io](https://rasbt.github.io)

- 這個連結在課程中有給過，但是這網頁說明的不只有參數調整的寫法，還包含 Stacking 的 Classifier 寫作細節，在看我們的範例之餘，如果還有其他疑問，建議也可以直接來官方網站挖。
- 其中 Stacking 內部參數的寫法，我們在這邊說明一下，例如下列參數：
  - 'randomforestclassifier\_n\_estimators': [10, 50]

n\_estimators 參數，可以看出不只有中間連結的底線要兩個，單模模型的呼叫，也需要把原本模型的大寫全部換成小寫，同學如果還有疑問，不妨可以自己試跑看看

- 提醒同學，時間 Stacking 執行會稍微有點久喔，建議先估計一下執行時間。



如何在 Kaggle 首戰中進入前 10%

Wille 個人心得 [網頁連結](#) (簡體)

- 而其中有詳細講解了 Stacking 的用法與他自己的寫法，同學可以參考程式本身，理解一下我們 Stacking 講解的未盡之處，雖然現在工具是方便多了，但是有一些想不通的細節，有程式碼可以推敲，我想會方便很多。



```

6
7 def fit_predict(self, X, y, T):
8     X = np.array(X)
9     y = np.array(y)
10    T = np.array(T)
11
12    folds = list(KFold(len(y), n_folds=self.n_folds, shuffle=True, random_state=2016))
13
14    S_train = np.zeros((X.shape[0], len(self.base_models)))
15    S_test = np.zeros((T.shape[0], len(self.base_models)))
16
17    for i, clf in enumerate(self.base_models):
18        S_test_i = np.zeros((T.shape[0], len(folds)))
19
20        for j, (train_idx, test_idx) in enumerate(folds):
21            X_train = X[train_idx]
22            y_train = y[train_idx]
23            X_holdout = X[test_idx]
24            # y_holdout = y[test_idx]
25            clf.fit(X_train, y_train)
26            y_pred = clf.predict(X_holdout)[: ]
27            S_train[test_idx, i] = y_pred
28            S_test_i[:, j] = clf.predict(T)[: ]
29
30        S_test[:, i] = S_test_i.mean(1)
31
32    self.stacker.fit(S_train, y)
33    y_pred = self.stacker.predict(S_test)[: ]
34    return y_pred
    
```

## 解題時



Sample Code & 作業

開始解題



下一步：閱讀範例與完成作業